

基于 Python 分析梦境数据的特征

陈劲豪, 叶琳珊, 余绵峰

清华大学 北京 100084

【摘要】 梦境常被认为是一种随机的生理现象, 但是近年有研究开始揭示梦境的特点及服从的规律。本研究以 SDDb 和 DreamBank 中爬虫获取的梦境回忆文本为原始材料, 对梦境的感情色彩及其影响因素进行了探索性数据分析, 并进一步探究了梦境中出现的实体频次分布和 Zipf 幂律分布的关系, 最后从网络几何的视角探讨了噩梦和其他梦境在拓扑结构中的差异, 为一些经典的关于梦境的理论提供了数据支持。

【关键词】 Python, 梦境, SDDb, DreamBank, Zipf 幂律分布, 网络几何

1 引言

做梦是人类一个重要的生理-心理现象: 自古以来, 人们晚上睡觉时就会做梦, 并且会在白天苏醒时记得自己的梦境。但是因为做梦是一个难以直接被观测的行为, 所以长久以来, 人们对梦境的研究仅限于阅读做梦者复述的情节, 这也导致早期人们对梦境的理解是极其玄幻的。

随着时代的发展和科学的进步, 人们逐渐意识到了做梦作为一种生理现象的唯物性, 进而开发出了诸如记录 EEG 等脑科学方法。但是因为基础知识和技术力有限, 脑科学视角的梦境研究充斥着大量的生理信号杂音, 而且难以大规模开展, 因此, “阅读做梦者复述的情节” 仍然是一个研究梦境的重要方式——只不过, 我们不再像古人一样专注于梦境中光怪陆离的画面、并试图解读所谓“神谕”; 而是以一种类似数学人文的范式, 对做梦者转述梦境的文本进行统计和建模分析, 以研究梦境文本作为研究梦境的代理。

目前可供研究的梦境文本主要有两类: 一类是纵向梦境序列, 即研究者们寻找乐于长期 (往往长达好几年) 记录自己每晚梦境的被试, 并在长期与被试的配合中获得时序的梦境文本; 由于在纵向梦境序列中, 我们往往很方便将被试记录的梦境与被试的真实生活状态进行对应, 因此纵向梦境序列很适合研究不同生命阶段或者生活中发生的事情对梦境的影响。另一类是横截面研究, 即研究者们在一个相对窄 (往往几天到几周) 的时间框

中, 对一个广大的人群进行梦境文本的收集; 横截面研究往往没有明显的时间结构, 但是我们可以通过在常规时期和具备突发事件的时段对一个人群进行横截面快照, 来研究不同性质的突发事件对人群整体梦境的影响。

在本工作中, 我们将利用 SDDb^[1] 和 DreamBank^[2] 数据库, 对现有关于梦境的统计与建模结论进行实证检验。具体研究内容将围绕以下内容展开:

1. 横截面研究的统计特征分析

- 检验心理学中的“波丽安娜法则”^{[3][4]}, 对比分析人类在潜意识状态中是否比在清醒状态下表现出更为积极的精神倾向。

- 探索做梦者的固有差异 (如性别) 以及重大社会环境变动 (如新冠疫情时期、乔治·弗洛伊德事件爆发期) 对人群整体梦境特征的扰动与影响。

- 引入有向图方法解析梦境实体的出现序列, 通过量化聚集系数、基尼系数和反馈环数量等指标, 揭示噩梦与常规梦境在结构特征上的根本区别。^[5]

2. 验证 Zipf 幂律分布^[6]

- 考察长期梦境序列中特定实体出现的频次, 检验其与频率排名之间是否呈现稳定的指数衰减关系。

2 实验

2.1 数据来源与清洗

2.1.1 SDDb

SDDb 有现成的 csv 文件，因此是不需要爬虫的；但是在 csv 文件中，每一条数据在记录梦境文本时都引入了大量的换行，对后续的数据处理不友好，因此我们利用正则表达式消除了这些数据内部的换行。

随后，在检查 SDDb 中收录的横截面梦境集时，我们发现有些被试会拒绝填写有效内容（例如梦境文本中出现“我不做梦”“我不想回答”“……”之类的无效文本），因此我们使用 LLM 清洗了这些低质量数据：因为我们认为无效文本很难写到 20 个词以上，我们规定【如果一条数据里的梦境文本长度大于 20 个词，那么这条数据是有效的】，仅获取梦境文本小于等于 20 个词的数据，并让 LLM 逐个判断是否属于无效内容、仅保留有效内容。注意此方法无法排除被试真的输出了 20 个词以上的无效文本的可能，但是我们认为绝大多数被试不会无聊到这个程度。

2.1.2 DreamBank

和 SDDb 不同，DreamBank 并没有现成的 csv 文件，因此是需要爬虫的；因此我们检视了 DreamBank 数据页面的 html 结构，并相应地写了爬虫代码。

后续我们发现，该爬虫代码无法获取 Kenneth 梦境集的梦境文本，只能爬到该梦境集每条数据的梦境标题；经检视 DreamBank 在该梦境集页面的 html 结构后，我们发现 Kenneth 梦境集是唯一一个写了梦境标题的数据集，因此其 html 结构和其他梦境集略有差异；因此我们对原先的爬虫代码稍加修改，便成功爬取了 Kenneth 梦境集的梦境文本。

最后，我们发现 DreamBank 中有个别梦境集不是用英文记录的——这些梦境集是明确被标记为【来自德国】的梦境集，梦境文本经查询也发现是德文，因此我们使用了 LLM 来翻译这些数据：我们把这个别梦境集中的文本提交给 LLM，让 LLM 把德文翻译为英文即可。注意在经过翻译后，这些德文数据集的梦境文本长度是没法和原先就用英文书写的梦境文本长度直接进行比较的，

不过翻译过程不会过度扭曲改变梦境中出现的实体和感情基调。

2.2 特征构建

2.2.1 梦境文本的词汇、主题、情感等特征

在对 SDDb 和 DreamBank 进行数据清洗后，我们仅关注每条数据的【梦境文本内容】和【该数据所来自的梦境集】；而我们一旦得到每条数据的梦境文本内容，就可以调用三个 python packages 进行文本分析：

我们调用 spaCy^[7]获取了关于梦境文本内容的词汇特点（词汇数、动词数、形容词数……），调用 VADER^[8]分析了每个梦境文本的情感色彩（“积极性”、“消极性”、“中性程度”和“综合打分”，同时我们计算“积极性”-“消极性”，构建了组合特征“差异”），调用 Empath^[9]分析了每个梦境文本重点描写了什么样的主题（“健康相关”“暴力相关”“友情相关”……）

2.2.2 梦境文本中含有的实体序列及频次

在探索噩梦与常规梦境的结构区别，我们调用了大模型：对于某个梦境集里的每一条数据，我们提取梦境文本，先判断它是不是噩梦，随后找出该梦境中出现的所有比较重要的实体（包括人物、物品等），并按照出现顺序有序地放入一个列表里储存。最后，针对每条数据对应的列表，我们利用 python 按照如下公式计算三个特征：聚集系数、基尼指数和反馈环数量。

在验证幂律分布时，我们同样调用了大模型，不过操作略微不一样：对于某个纵向梦境集，我们只提取整个梦境集中每个重要人物，并对这些人物的出现频次进行计数。

聚集系数、基尼指数和反馈环数量的计算公式如下：

1. 聚集系数 (Clustering Coefficient)

$$C = \frac{1}{|V|} \sum_{v \in V} C_v, \quad C_v = \frac{2T_v}{d_v(d_v - 1)}$$

符号含义： C ：整张图的平均聚集系数； V ：图中的节点集合，在这里表示梦境中出现过的实体集合； $|V|$ ：节点数量； v ：某一个节点； C_v ：节点 v 的局部聚集系数； T_v ：节点 v 的邻居之间实际形成的连接数量； d_v ：节点 v 的度数。

指标理解：聚集系数衡量图中节点局部形成闭环或紧密连接的程度。值越高，说明梦境中的实体更容易围绕局部小团体反复连接，叙事更像在同一片场景或实体关系中打转；值越低，说明实体连接更松散或更线性。

2. 基尼系数 (Gini Coefficient)

$$G = \frac{\sum_{i=1}^n (2i - n - 1)x_i}{n \sum_{i=1}^n x_i}$$

符号含义： G ：基尼系数； n ：节点数量； x_i ：按从小到大排序后的第 i 个节点度数； i ：排序后节点度数的位置编号，从 1 到 n ； $\sum_{i=1}^n x_i$ ：所有节点度数之和。

指标理解：基尼系数衡量节点度分布是否集中。值越高，说明少数实体拥有更多连接，梦境更可能被某些关键人物、地点或物体主导；值越低，说明连接分布更均匀，各实体在叙事中的参与程度更接近。

3. 反馈环数量 (Feedback Loops)

$$F = |\mathcal{C}(G)|$$

符号含义： F ：反馈环数量； G ：由梦境实体序列构建出的有向图； $\mathcal{C}(G)$ ：图 G 中所有简单有向环的集合； $|\mathcal{C}(G)|$ ：简单有向环的数量。

指标理解：反馈环数量衡量梦境实体转移中出现闭环路径的多少。值越高，说明叙事越容易从某些实体出发又回到原来的实体，梦境结构更循环；值越低，说明情节推进更少回到原点，更接近线性展开。

3 实验结果与分析

3.1 现实生活环境对梦境情感与内容的影响

3.1.1 验证波丽安娜法则

针对 SDDb 与 DreamBank 数据库中的各梦境集，本研究首先计算了单条梦境文本的 VADER 积极性与消极性指数。通过散点分布图进行可视化（图中右侧红色散点表征积极性指数，左侧蓝色散点表征消极性指数）可以观察到，多数梦境集的整体情感极性大致对称，部分梦境集呈现出积极性高于消极性（或反之）的倾向。

为进一步检验情感偏向的显著性，本研究计

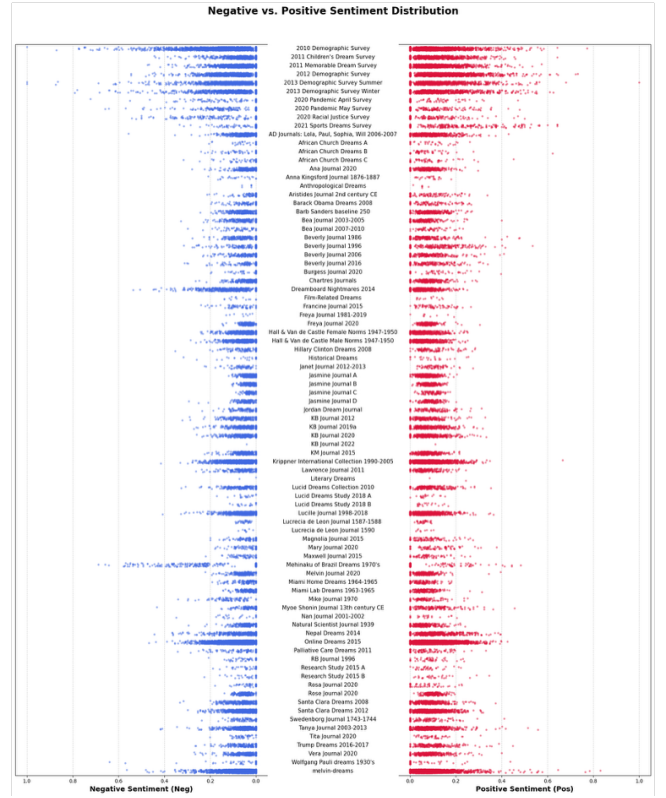


图 1 SDDb 数据库中不同梦境集的积极性与消极性指数

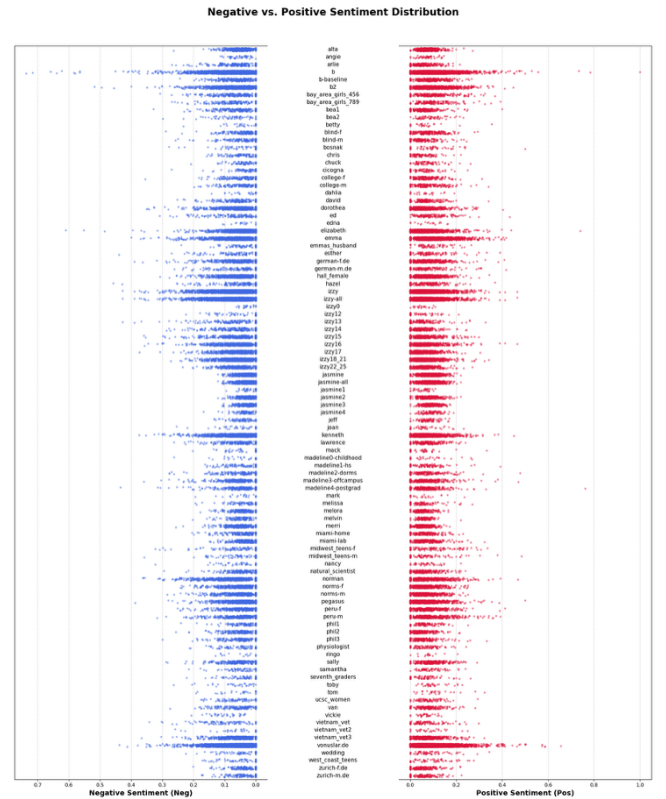


图 2 DreamBank 数据库中不同梦境集的积极性与消极性指数

算了各梦境集内单条数据的 VADER 差异值，并对其分布进行了显著性检验及可视化标注：若差异值显著大于 0（整体偏积极），该梦境集内的散点统一标记为蓝色；若差异值显著小于 0（整体偏消极），则标记为红色；若差异值与 0 无显著统计学差异，则标记为灰色。




图 3 SDDb 中数据库中不同梦境集单条数据的 VADER 复合差异值




图 4 DreamBank 数据库中不同梦境集单条数据的 VADER 复合差异值

统计结果表明，在两个数据库中，绝大多数梦境集的 VADER 差异值显著大于 0 或无显著差异，仅有极少数梦境集呈现出显著小于 0 的分布特征。这一统计现象为波丽安娜法则提供了实证支持，即“人类在潜意识（梦境）状态下的精神状态普遍偏向积极”。

3.1.2 固有特征（性别与年龄）对梦境文本的影响分析

为探究性别、年龄等固有个体属性对梦境内容的具体影响，本研究提取了具备单一性别或特定年龄段标签的梦境子集，并量化评估了梦境文本中各类典型主题特征的得分。

统计对比结果显示，总体而言，男性与女性被试在等常见梦境主题上的得分分布并未表现出显著差异。这一结果表明，关于“某一性别比另一性别更易产生特定负面梦境”等常见假设在当前样本下缺乏明确的统计学证据支持。与此同时，横跨不同年龄组的量化对比亦表明，个体年龄的跨度

差异对梦境核心主题与情绪的扰动作用相对有限。




图 5 性别与年龄对梦境文本的诸多方面影响并不大

3.1.3 重大社会环境变动（新冠疫情、乔治-弗洛伊德事件）对梦境文本的影响分析

除个体固有特征外，本研究进一步考察了重大社会公共事件对群体梦境的宏观扰动。

在对比新冠疫情期梦境集与基准线（Baseline）梦境集时，数据呈现出明显的特征变化：疫情期间的受访者普遍趋向于使用更简短的文本描述梦境，同时，梦境中健康相关主题的词频与负面情绪指标发生显著攀升。这一结果直观地反映了公共卫生危机所带来的生理威胁与心理焦虑在群体潜意识层面的映射。




图 6 疫情期间，人们输出的梦境文本长度变短，关注健康程度、负面情绪上升

相较之下，2020 年 5 月（即乔治·弗洛伊德

事件爆发期) 梦境集相对于基准线的偏离幅度更为剧烈。除梦境文本长度普遍缩减外, 该阶段梦境中的负面情绪与暴力主题呈现出激增态势, 印证了该事件在社会层面引发的强烈愤怒与不安。然而值得注意的是, 同一时期梦境中涉及“友情”与“家庭”的主题得分亦出现了同步上升。结合生理心理学的视角, 这可以得到一种合理的解释: 梦境是大脑潜意识对真实生活情境的预演; 当个体在现实生活中感知到强烈胁迫时, 往往会在梦境中演练应对危机的手段。据此推测, 2020 年 5 月梦境集中友情与家庭主题的涌现, 极可能是做梦者在面临外部危机时, 潜意识中强化了与核心社会支持系统(家人、朋友)的联结与互动。




图 7 乔治·弗洛伊德事件期间, 人们输出的梦境文本和常规时期相比有较多的区别

3.2 噩梦的网络拓扑结构特征

人们对噩梦常常有如下描述: 在噩梦中, 同一个恐怖的场景反复出现, 仿佛被困在一个无法逃离的循环中。抛开主观情感的渲染, 这本质上是一个关于梦境拓扑结构的描述: 即积极梦境貌似容易呈现“线性叙事”拓扑结构, 而负面梦境容易呈现“循环结构”。

为了验证该描述是否属实, 我们借用了网络拓扑中的有向图方法, 计算了噩梦和常规梦境中出

现实体序列的三个描述循环结构的特征——聚集系数、基尼指数和反馈环数量——并先初步绘制了箱线图; 从箱线图来看, 可以发现消极梦境的三个核心指标高于积极梦境, 初步印证了“消极梦境呈现循环结构, 积极梦境呈现线性结构”的结论。




图 8 箱线图展示噩梦与常规梦境的聚集系数、基尼指数和反馈环数量差异

为了量化这个差异, 我们计算了噩梦样本和常规梦境样本中这三个特征的统计量并进行了对比, 可以发现在三个核心指标上, 消极梦境的均值都高于积极梦境, 尤其是消极梦境的反馈环均值约为积极梦境的 2 倍, 而基尼系数高出 7.5%。

指标	统计量	正向梦境	负向梦境
聚集系数	均值	0.0849	0.099
	中位数	0	0
	标准差	0.156	0.1543
基尼系数	均值	0.1642	0.1766
	中位数	0.1667	0.1714
	标准差	0.0743	0.0727
反馈环数	均值	4.4288	8.3817
	中位数	2	3
	标准差	75.6527	192.7977

图 9 表格量化展示噩梦与常规梦境的聚集系数、基尼指数和反馈环数量差异

基于消极梦境的反馈环数量明显多于积极梦

境，基尼指数略高于积极梦境等观察，我们得出结论：噩梦并非简单的“可怕内容”，而确实具有独特的拓扑结构——情节反复回到起点，形成无法逃离的循环。

3.3 验证梦境人物出现的频率服从 Zipf 幂律分布

最后，“日有所思，夜有所梦”也是人们对梦境的常见看法之一，它暗示着一个人在一段时间内做的梦境中，有些人物出现的频率会比其他人物更高；因此，为了探究梦境中不同人物出现的频率是否服从某种数学规律，我们提取了 61 个纵向梦境集，分别统计了每个梦境集中某个人物出现的频率，并对同一个梦境集中人物出现的频率进行了排名。

3.3.1 人物频率与排名的线性回归分析

我们以人物出现的排名为横坐标，出现频率为纵坐标绘图，发现这两个变量之间明显不是线性关系。




图 10 人物出现的频率和排名之间不是线性关系

接着我们查阅了相关的文献，在文献中找到了可以参考的结论：梦境中人物出现的频率应该符合 Zipf 幂律分布。也就是说，我们所定义的频率与排名两个变量之间是幂函数的对应关系，直观来看，也就是它们各自的对数值应该存在较强的线性关系。

随后我们重新处理数据，这一次我们以出现频率和排名的对数值作为两个变量绘图，的确发现了较为明显的线性关系。




图 11 人物出现的频率和排名经对数变换后呈线性关系

3.3.2 拟合度 (R^2) 评估与结论

为了定量描述该线性关系的准确性，我们还对 61 个出现频率和排名的对数值的样本进行了线性回归分析（为了进一步保证准确性，我们移除了所有出现频率为 1 的人物），发现大部分梦境数据集的 R^2 大于 0.9，只有一些样本量较少的梦境集会有比较明显的偏移。




图 12 人物出现的频率和排名经对数变换后线性关系的 R^2 普遍大于 0.9

从结果上看：初步可以认为幂律分布假设成立。考虑到提出 Zipf 幂律分布的论文仅用 5 个梦境集并且使用的是人工标注，而我们在 61 个梦境集里均验证了这个现象，我们得到的最终的结论进一步验证了梦境中人物出现频率服从 Zipf 幂律分布的结论。

4 讨论

本研究依托 SDDb 与 DreamBank 两个梦境数据库，针对梦境的现实影响因素、幂律分布规律及梦境拓扑结构三个维度开展了研究，结果大致符合预期，但在数据获取与分析部分仍然存在若干值得讨论与反思的问题。

首先，数据来源本身可能存在一定的局限性。研究采用的两份数据集虽然样本规模较大，各自都有数万条数据，但是其梦境样本本身可能存在原生性的调查偏差。第一点，两份梦境集的数据虽然均来自主动参与调研并且阐述梦境的人群，但是仍然存在不愿意回答梦境或者坚称自己不做梦的情况，这可能会给第一部分的因果性分析带来影响，如愿意记录梦境的人群可能本身就对梦境比较敏感，其梦境内容与其中包含的情感可能与不参与梦境记录的人群本来就存在一定差异，如考虑到现实中的负面情绪可能导致有受访者不愿意参与梦境调研，从而导致统计结果中关于负面梦境的比例可能比实际值偏低，进而影响这部分的统计结果。第二点，虽然梦境集覆盖了男女老幼

不同时期以及残障、有过战争经历的人群，但是其对于后两种群体并非群体批量采集，而是针对单人的长期梦境记录。仅针对单一个体的梦境记录可能受到自身记忆衰退、持续性的主观修饰以及自身当前情绪状况等因素影响，会为结果分析带来偶然性误差。

其次，数据处理部分也可能存在分析误差。在 3.1 中，本文使用 VADER、Empath 和 spaCy 等工具，基于词典和词性统计来处理梦境，但由于梦境可能存在隐喻或者不符合正常逻辑的内容，基于词典的分析工具可能难以处理这种差异，这部分得到的结果只能看作模糊处理，但人工实际检查发现隐喻或不合逻辑的内容在梦境集中并不多见，因此此部分结果应当较为可信。在 3.2、3.3 中，本文采取 LLM 大模型对结果进行处理，如在课题二中，尽管在提示词中强调要注意合并相同人物的不同称呼，如同一人的亲昵叫法，也考虑到动物拟人等注意事项，但大模型输出结果本身仍然可能存在误差，且这部分的结果无法人工逐一复核，但我们针对小批量数据集进行多次 LLM 处理后发现结果相差并不大，因此这部分所得结果可看作较为接近实际的近似值。另外值得一提的是，大模型处理时并未将 *someone* 这类模糊代指词去掉，经过核对，过半数据集的结果中均包含 *someone* 这一人物实体，但是几乎所有涉及该实体的数据集中的该实体 *rank* 值都处于中部，也就是该实体出现频率并不高，考虑到每一梦境集中实体类型众多，该单一数据点是否去除并不影响后续的回归统计结果。此外，由于 LLM 调用花费较大，我们在课题二三部分即使已经共同进行 LLM 调用得到了可以共用的结果，但还是只处理了两万七千条数据，并未对全体梦境数据进行处理，但考虑到这部分是针对大批量梦境的统计分析，某一梦境集具体来源如何并不影响结果，因此这部分数据足以支撑研究结果的确立。

另外，本研究只解释了梦境中的统计关系而非因果关系。尽管在 3.1 中，我们发现疫情、社会冲突等重大外部事件可能影响到梦境内容的结论因果关系较为显著，但 3.2 三中本文仅证实了负面梦境往往具有更多反馈环和循环结构，而这在本质上只属于相关性分析，尚不足以说明是负面梦境本身会导致更独特的拓扑结构，还是更多的反

馈环等拓扑结构会导致梦境变为负面。

5 结论

本工作以“梦的结构”为主题，基于 SDDb 和 DreamBank 两大公开梦境数据库，综合运用数据爬虫、数据清洗、词性统计、情感分析、LLM 处理等方法，对梦境内容、结构及其内在规律进行了系统探索。

在研究现实生活环境对梦境情感与内容的影响中，本文通过情感分析和主题特征提取发现，梦境样本整体呈现出轻微积极倾向；同时，性别和年龄等个体特征对梦境内容的影响相对有限，但疫情、社会冲突等重大外部环境因素则对梦境内容表现出更明显的影响。

在研究噩梦的网络拓扑结构特征中，本文发现，负面梦境具有更多反馈环、更高的基尼系数以及更高的聚集系数。其中反馈环数量是区分积极梦境与消极梦境最显著的指标，指出了噩梦具有独特的拓扑结构。

在验证梦境人物实体频率的 Zipf 幂律分布中，本文利用 LLM 自然语言处理，针对 61 个梦境集的人物实体出现频率进行了统计与回归，发现人物实体出现频率满足幂律分布，即人物实体出现的频率与排名之间存在幂函数关系。

综上所述，本研究从梦境情感内容、实体出现的统计规律和噩梦的特殊拓扑结构三个层面对梦境进行了分析，揭示了现实生活确实影响了我们的梦境，也指出了梦境内部实体出现的频率存在普遍的统计规律，不同类型的梦境如噩梦也存在其特殊的拓扑结构，所得结论基本符合预期，为梦境研究提供了可供参考的统计结果。

参考文献

- [1] BULKELEY K. Digital dream analysis: a revised method[J/OL]. *Consciousness and Cognition*, 2014, 29: 159-170. DOI:10.1016/j.concog.2014.08.015.
- [2] DOMHOFF G W, SCHNEIDER A. Studying dream content using the archive and search engine on dreamBank.net[J/OL]. *Consciousness and cognition*, 2008, 17(4): 1238-1247. DOI:10.1016/j.concog.2008.06.010.
- [3] BOUCHER J, OSGOOD C E. The pollyanna hypothesis[J/OL]. *Journal of Verbal Learning and Verbal Behavior*, 1969, 8(1): 1-8. DOI:10.1016/S0022-5371(69)80002-2.

-
- [4] MATLIN M W, STANG D J. The pollyanna principle: selectivity in language, memory, and thought[M]. Schenkman Publishing Company, 1978.
- [5] LECKIE L, BERSHAD A K, HEPPLER J, et al. The content and structure of dreams are coupled to affect[A/OL]. arXiv. <https://arxiv.org/abs/2409.14279>. DOI:10.48550/arXiv.2409.14279.
- [6] SCHWEICKERT R, XI Z Z, VIAU-QUESNEL C, et al. Power law distribution of frequencies of characters in dreams explained by random walk on semantic network[J/OL]. International Journal of Dream Research, 2020, 13(2): 192-201. DOI:10.11588/ijodr.2020.2.71370.
- [7] HONNIBAL M, MONTANI I, VAN LANDEGHEM S, et al. spaCy: Industrial-strength Natural Language Processing in Python[J/OL]. 2020. DOI:10.5281/zenodo.1212303.
- [8] HUTTO C J, GILBERT E. VADER: a parsimonious rule-based model for sentiment analysis of social media text[C/OL]// Proceedings of the international AAAI conference on web and social media: v.8. 2014: 216-225. DOI:10.1609/icwsm.v8i1.14550.
- [9] FAST E, CHEN B B, BERNSTEIN M S. Empath: understanding topic signals in large-scale text[C/OL]//Proceedings of the 2016 CHI conference on human factors in computing systems. 2016: 4647-4657. DOI:10.1145/2858036.2858535.